




NHẬP MÔN KHOA HỌC DỮ LIỆU

#9. Thư viện Pandas (1)

**INTRODUCTION TO
DATA SCIENCE**

- 1. Giới thiệu và cài đặt pandas**
- 2. Cấu trúc dữ liệu trong pandas**
- 3. Làm việc với series**
- 4. Làm việc với dataframe**
- 5. Bài tập**

Phần 1

Giới thiệu và cài đặt pandas



Cài đặt: “**pip install pandas**”

- “pandas” là thư viện mở rộng từ numpy, chuyên để xử lý dữ liệu cấu trúc dạng bảng
- Tên “pandas” là dạng số nhiều của “panel data”



Đặc điểm nổi bật của pandas

- Đọc dữ liệu từ nhiều định dạng
- Liên kết dữ liệu và tích hợp xử lý dữ liệu bị thiếu
- Xoay và chuyển đổi chiều của dữ liệu dễ dàng
- Tách, đánh chỉ mục và chia nhỏ các tập dữ liệu lớn dựa trên nhãn
- Có thể nhóm dữ liệu cho các mục đích hợp nhất và chuyển đổi
- Lọc dữ liệu và thực hiện query trên dữ liệu
- Xử lý dữ liệu chuỗi thời gian và lấy mẫu

Phần 2

Cấu trúc dữ liệu trong pandas



Cấu trúc dữ liệu trong pandas

- **Dữ liệu của pandas có 3 cấu trúc chính:**
 1. **Series (loạt):** cấu trúc 1 chiều, mảng dữ liệu đồng nhất
 2. **Dataframe (khung):** cấu trúc 2 chiều, dữ liệu trên các cột là đồng nhất (có phần giống như table trong SQL, nhưng với các dòng được đặt tên)
 3. **Panel (bảng):** cấu trúc 3 chiều, có thể xem như một tập các dataframe với thông tin bổ sung
- Dữ liệu series gần giống kiểu array trong numpy, nhưng có 2 điểm khác biệt quan trọng:
 - Chấp nhận dữ liệu thiếu (NaN – không xác định)
 - Hệ thống chỉ mục phong phú (giống dictionary?)



Cấu trúc dataframe

- Dữ liệu 2 chiều
- Các cột có tên
- Dữ liệu trên cột là đồng nhất (series?)
- Các dòng có thể có tên
- Có thể có ô thiếu dữ liệu

	country	population	area	capital
BR	Brazil	200	8515767	Brasilia
RU	Russia	144	17098242	Moscow
IN	India	1252	3287590	New Delhi
CH	China	1357	9596961	Beijing
SA	South Africa	55	1221037	Pretoria



Cấu trúc panel

- Dữ liệu 3 chiều
- Một tập các dataframe
- Các dataframe có cấu trúc tương đồng
- Có thể có các thông tin bổ sung cho từng dataframe

		Open	Close
Major	Minor		
3/31/2015	IBM	23.602	132.903
	APPL	421.412	212.665
	CVX	568.055	409.201
	BHP	487.414	515.413
4/30/2015	IBM	150.868	457.895
	APPL	204.729	957.179
	CVX	90.679	888.687
	BHP	831.527	714.202
5/31/2015	IBM	788.582	922.422
	APPL	329.716	304.964
	CVX	36.578	981.508
	BHP	313.848	882.293

Phần 3

Làm việc với series



Tạo dữ liệu series (1)

```
import pandas as pd  
import numpy as np
```

```
S = pd.Series(np.random.randint(100, size = 4))
```

```
print(S)  
print(S.index)  
print(S.values)
```

```
0    73  
1    80  
2     4  
3     7  
dtype: int32  
RangeIndex(start=0, stop=4, step=1)  
[73 80  4  7]
```



Tạo dữ liệu series (2)

```
import pandas as pd
```

```
import numpy as np
```

```
chi_so = ["Ke toan", "KT", "CNTT", "Co khi"]
```

```
gia_tri = [310, 360, 580, 340]
```

```
S = pd.Series(gia_tri, index=chi_so)
```

```
print(S)
```

```
print(S.index)
```

```
print(S.values)
```

```
Ke toan    310
```

```
KT         360
```

```
CNTT       580
```

```
Co khi     340
```

```
dtype: int64
```

```
Index(['Ke toan', 'KT', 'CNTT', 'Co khi'], dtype='object')
```

```
[310 360 580 340]
```



Tạo dữ liệu series (3)

```
import pandas as pd
```

```
import numpy as np
```

```
chi_so = ["KT", "KT", "CNTT", "Co khi"] # trùng nhau
```

```
gia_tri = [310, 360, 580, 340]
```

```
S = pd.Series(gia_tri, index=chi_so)
```

```
print(S)
```

```
print(S.index)
```

```
print(S.values)
```

```
KT          310
KT          360
CNTT        580
Co khi      340
dtype: int64
Index(['Ke toan', 'KT', 'CNTT', 'Co khi'], dtype='object')
[310 360 580 340]
```



Truy vấn thông qua chỉ số

```
import pandas as pd
```

```
import numpy as np
```

```
chi_so = ["KT", "KT", "CNTT", "Co khi"] # trùng nhau
```

```
gia_tri = [310, 360, 580, 340]
```

```
S = pd.Series(gia_tri, index=chi_so)
```

```
print(S['Co khi'])
```

```
print(S['KT'])
```

```
print(S.CNTT)
```

```
340
KT    310
KT    360
dtype: int64
580
```



Phép toán trên series

```
import pandas as pd
import numpy as np
```

```
chi_so = ["Ke toan", "KT", "CNTT", "Co khi"]
```

```
gia_tri = [310, 360, 580, 340]
```

```
# chỉ số giống nhau thì tính gộp, nếu không thì NaN
```

```
S = pd.Series(gia_tri, index=chi_so)
```

```
P = pd.Series([100, 100], ['CNTT', 'PM'])
```

```
Y = S + P
```

```
print(Y)
```

CNTT	680.0
Co khi	NaN
KT	NaN
Ke toan	NaN
PM	NaN
dtype: float64	



Phép toán trên series

- Nguyên tắc chung của việc thực hiện phép toán trên series như sau:
- Nếu là phép toán giữa 2 series, thì các giá trị cùng chỉ số sẽ thực hiện phép toán với nhau, trường hợp không có giá trị ở cả 2 series thì trả về NaN
- Nếu là phép toán giữa series và 1 số, thì thực hiện phép toán trên số đó với tất cả các giá trị trong series



Một số phương thức hữu ích

- **S.axes**: trả về danh sách các chỉ mục của S
- **S.dtype**: trả về kiểu dữ liệu các phần tử của S
- **S.empty**: trả về True nếu S rỗng
- **S.ndim**: trả về số chiều của S (1)
- **S.size**: trả về số phần tử của S
- **S.values**: trả về list các phần tử của S
- **S.head(n)**: trả về n phần tử đầu tiên của S
- **S.tail(n)**: trả về n phần tử cuối cùng của S



Apply() một hàm khác trên series

```
import pandas as pd
import numpy as np

def Tang(x):
    return x if x > 500 else x + 1000

chi_so = ["Ke toan", "KT", "CNTT", "Co khi"]
gia_tri = [310, 360, 580, 340]
S = pd.Series(gia_tri, chi_so)
# áp dụng Tang trên S (không thay đổi S)
print(S.apply(Tang))
```

Ke toan	1310
KT	1360
CNTT	580
Co khi	1340
dtype: int64	

Phần 4

Làm việc với dataframe



Khởi tạo dataframe

- **Cú pháp chung**

```
pandas.DataFrame(data, index, columns, dtype, copy)
```

- **Trong đó**

- **'data'**: sẽ nhận giá trị từ nhiều kiểu khác nhau như list, dictionary, ndarray, series,... và cả các DataFrame khác
- **'index'**: là nhãn chỉ mục hàng của dataframe
- **'column'**: là nhãn chỉ mục cột của dataframe
- **'dtype'**: là kiểu dữ liệu cho mỗi cột
- **'copy'**: nhận giá trị True/False để chỉ rõ dữ liệu có được copy sang vùng nhớ mới không? Mặc định là False



Tạo dataframe từ list

```
import pandas as pd
names = ['MIT', "Stanford", "DHTL"]
df = pd.DataFrame(names)
print(df)
```

	0
0	MIT
1	Stanford
2	DHTL

```
names_rank = [['MIT',1],["Stanford",2],["DHTL",200]]
df = pd.DataFrame(names_rank)
print(df)
```

	0	1
0	MIT	1
1	Stanford	2
2	DHTL	200



Tạo dataframe từ dictionary các list

```
crimes_rates = {  
    "Year": [1960, 1961, 1962, 1963, 1964],  
    "Population": [179323175, 182992000, 185771000, 188483000, 191141000],  
    "Total": [3384200, 3488000, 3752200, 4109500, 4564600],  
    "Violent": [288460, 289390, 301510, 316970, 364220]  
}  
crimes_dataframe = pd.DataFrame(crimes_rates)  
print(crimes_dataframe)
```

	Population	Total	Violent	Year
0	179323175	3384200	288460	1960
1	182992000	3488000	289390	1961
2	185771000	3752200	301510	1962
3	188483000	4109500	316970	1963
4	191141000	4564600	364220	1964



Tạo dataframe từ list các dictionary

```
data = [  
    {'MIT': 5000, 'Stanford': 4500, "DHTL":15000},  
    {'MIT': 1, 'Stanford': 2, "DHTL":200}  
]
```

```
df = pd.DataFrame(data, index=['NumOfStudents', "ranking"])  
print(df)  
print(df.DHTL.dtype)
```

	DHTL	MIT	Stanford
NumOfStudents	15000	5000	4500
ranking	200	1	2

dtype('int64')



Tạo dataframe từ dictionary series

```
data = {  
    "one": pd.Series([1,23,45], index = [1,2,3]),  
    "two": pd.Series([1000,2400,1132,3434], index = [1,2,3,4])  
}  
df = pd.DataFrame(data)  
print(df)
```

	one	two
1	1.0	1000
2	23.0	2400
3	45.0	1132
4	NaN	3434



Đọc dữ liệu từ file .csv

- **Nội dung củ file brics.csv:**

- Số liệu về các quốc gia thuộc khối BRICS
- Sử dụng dấu phẩy để ngăn giữa các dữ liệu
- Mỗi dữ liệu trên 1 dòng
- Dòng đầu tiên là tên các cột

```
,country,population,area,capital  
BR,Brazil,200,8515767,Brasilia  
RU,Russia,144,17098242,Moscow  
IN,India,1252,3287590,New Delhi  
CH,China,1357,9596961,Beijing  
SA,South Africa,55,1221037,Pretoria
```



Đọc dữ liệu từ file .csv

```
import pandas as pd
```

```
d = pd.read_csv("brics.csv")
```

```
print(d)
```

	Unnamed: 0	country	population	area	capital
0	BR	Brazil	200	8515767	Brasilia
1	RU	Russia	144	17098242	Moscow
2	IN	India	1252	3287590	New Delhi
3	CH	China	1357	9596961	Beijing
4	SA	South Africa	55	1221037	Pretoria



Đọc dữ liệu từ file .csv

```
import pandas as pd  
# đọc dữ liệu và quy định cột 0 dùng làm chỉ số dòng  
d = pd.read_csv("brics.csv", index_col = 0)  
print(d)
```

	country	population	area	capital
BR	Brazil	200	8515767	Brasilia
RU	Russia	144	17098242	Moscow
IN	India	1252	3287590	New Delhi
CH	China	1357	9596961	Beijing
SA	South Africa	55	1221037	Pretoria



Truy cập theo từng cột

- Sử dụng tên cột làm chỉ số hoặc dùng luôn tên cột
- Việc truy cập này trả về tham chiếu đến dữ liệu, vì vậy có thể sử dụng phép gán để cập nhật dữ liệu theo cột

```
print(brics["country"])
```

```
BR Brazil
```

```
RU Russia
```

```
IN India
```

```
CH China
```

```
SA South Africa
```

```
Name: country, dtype: object
```

```
print(brics.country)
```

```
BR Brazil
```

```
RU Russia
```

```
IN India
```

```
CH China
```

```
SA South Africa
```

```
Name: country, dtype: object
```



Thêm một cột (1)

- **Bằng cách sử dụng một cột mới chưa có**

```
brics["on_earth"] = [True, True, True, True, True]
print(brics)
```

	country	population	area	capital	on_earth
BR	Brazil	200	8515767	Brasilia	True
RU	Russia	144	17098242	Moscow	True
IN	India	1252	3287590	New Delhi	True
CH	China	1357	9596961	Beijing	True
SA	South Africa	55	1221037	Pretoria	True



Thêm một cột (2)

- **Bằng cách sử dụng một cột mới chưa có và thiết lập công thức phù hợp**

```
brics["density"] = brics["population"] / brics["area"] * 1000000
print(brics)
```

	country	population	area	capital	on_earth	density
BR	Brazil	200	8515767	Brasilia	True	23.485847
RU	Russia	144	17098242	Moscow	True	8.421918
IN	India	1252	3287590	New Delhi	True	380.826076
CH	China	1357	9596961	Beijing	True	141.398928
SA	South Africa	55	1221037	Pretoria	True	45.043680



Truy cập dòng dùng loc

- **Bằng cách sử dụng một cột mới chưa có và thiết lập công thức phù hợp**

```
print(brics.loc["BR"])
```

country	Brazil
---------	--------

population	200
------------	-----

area	8515767
------	---------

capital	Brasilia
---------	----------

density	23.48585
---------	----------

on earth	True
----------	------

Name: BR, dtype: object



Truy cập vào từng ô trên dataframe

- **Bằng cách kết hợp chỉ mục dòng và cột**

```
print(brics.loc["CH","capital"])
```

Beijing

```
print(brics["capital"].loc["CH"])
```

Beijing

```
print(brics.loc["CH"]["capital"])
```

Beijing



Xóa dòng hoặc cột bằng drop

```
# tạo ra dataframe mới bằng cách xóa 2 cột  
print(d.drop(["area", "population"], axis=1))  
# trường hợp muốn xóa trên d, thêm tham số inplace=True  
d.drop(["area", "population"], axis=1, inplace=True)  
print(d)
```

	country	capital
BR	Brazil	Brasilia
RU	Russia	Moscow
IN	India	New Delhi
CH	China	Beijing
SA	South Africa	Pretoria



Tính tổng và tổng tích lũy

tính tổng của cột population, trả về tổng

```
print(d.population.sum())
```

tính tổng của cột population, trả về các tổng trong quá trình cộng

```
print(d.population.cumsum())
```

```
3008
```

```
BR      200
```

```
RU      344
```

```
IN     1596
```

```
CH     2953
```

```
SA     3008
```

```
Name: population, dtype: int64
```



Chuyển vị dataframe

```
print(d.T)
```

	BR	RU	IN	CH	SA
country	Brazil	Russia	India	China	South Africa
population	200	144	1252	1357	55
area	8515767	17098242	3287590	9596961	1221037
capital	Brasilia	Moscow	New Delhi	Beijing	Pretoria



Xem lướt qua về dữ liệu


```
import pandas as pd
import matplotlib.pyplot as plt
d = pd.read_csv("brics.csv", index_col = 0)
d.describe()
```

	population	area
count	5.000000	5.000000e+00
mean	601.600000	7.943919e+06
std	644.806405	6.199591e+06
min	55.000000	1.221037e+06
25%	144.000000	3.287590e+06
50%	200.000000	8.515767e+06
75%	1252.000000	9.596961e+06
max	1357.000000	1.709824e+07



Kết hợp giữa pandas và matplotlib

```
import pandas as pd
import matplotlib.pyplot as plt
d = pd.read_csv("brics.csv", index_col = 0)
d.area.plot(kind='bar')
plt.show()
```



Phần 5

Bài tập

- Nhập file dữ liệu từ file k59.csv. Yêu cầu thực hiện:
 1. In dữ liệu ra màn hình
 2. In 5 dòng đầu tiên và 5 dòng cuối cùng của dữ liệu ra màn hình
 3. Thống kê xem lớp có bao nhiêu bạn điểm loại giỏi (điểm từ 8 trở lên)
 4. Thống kê xem lớp có bao nhiêu bạn trượt môn (điểm dưới 4 hoặc không có điểm)
 5. Vẽ đồ thị histogram minh họa phân bố điểm số của lớp (trục giá trị từ 0 đến 10, không có được tính điểm 0)

Gợi ý

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

```
d = pd.read_csv("k59.csv", index_col = 0)
```

```
print(d) # câu 1: in dữ liệu ra màn hình
```

```
print(d.head(5)) # câu 2: in 5 dòng đầu tiên
```

```
print(d.tail(5)) # câu 2: in 5 dòng cuối cùng
```

```
print(len(d[d.Diem >= 8])) # câu 3: thống kê loại giỏi
```


câu 4: thống kê trượt môn

```
print(len(d[(d.Diem < 4) | (d.Diem.isnull())]))
```

câu 5: vẽ đồ thị histogram phân bố điểm

```
d.Diem.plot(kind='hist', bins=10)
```

```
plt.show()
```

gán cho những dòng thiếu điểm thành điểm 0

```
d.Diem.fillna(0, inplace=True)
```

thống kê theo loại điểm (so sánh xem khác histogram ở điểm nào?)

cách khác: `d.groupby('Diem').count()['MaSV'].plot(kind='bar')`

```
d.Diem.value_counts().sort_index().plot('bar')
```

```
plt.show()
```

KẾT CHƯƠNG

**XIN CHÂN
CHÂN THÀNH
CẢM ƠN!**

‘Quý vị đã dành thời gian
lắng nghe và theo dõi
nội dung trình bày.



Hy vọng kiến thức này mang lại giá trị. ✓